

CERTIFICATION PROFESSIONNELLE

« Concevoir et implémenter une solution d'intelligence artificielle »

ÉNONCÉ DU CAS D'USAGE

IA de détection précoce du décrochage étudiant

Dossier de fin de formation — Promotion en cours

Information	Valeur
Intitulé du projet	Détection précoce des étudiants en risque de décrochage en L1
Type de problème	Apprentissage supervisé — classification binaire (cible principale) + régression (cible secondaire)
Jeux de données fournis	decrochage_etudiants_complet_V5.csv (~5 200 lignes) · échantillon (50 lignes) · catalogue_formations_V5.csv
Durée de production	3 semaines (notebook + support)
Soutenance orale	1 heure (30 min présentation + 30 min échanges), à distance ou en présentiel
Compétences évaluées	Référentiel complet C1 → C9

1. Contexte général

Une université pluridisciplinaire constate un taux d'abandon élevé en première année de licence (L1). La direction de la réussite étudiante souhaite déployer une solution d'intelligence artificielle de détection précoce du décrochage afin d'identifier, dès le milieu du premier semestre, les étudiants à risque et de déclencher des dispositifs d'accompagnement (tutorat, soutien méthodologique, aide sociale).

Les objectifs métier de la solution sont les suivants :

- prédire, à mi-parcours, le risque de décrochage (interruption de la formation) d'un étudiant à partir de ses données académiques, d'engagement et de contexte ;
- estimer la moyenne finale attendue afin de prioriser et calibrer l'accompagnement ;
- fournir aux équipes pédagogiques des indicateurs explicables, tout en garantissant un usage éthique et conforme des données étudiantes.

Le candidat doit **concevoir, documenter, modéliser et proposer une stratégie d'industrialisation** de cette solution d'IA, de bout en bout, dans un notebook unique couvrant l'ensemble des compétences du référentiel (C1 à C9).

Important : vous êtes autorisé(e) à enrichir, filtrer, corriger ou ré-échantillonner les données, et à reformuler certaines hypothèses du cas, à condition de **documenter chaque décision dans le journal de bord**.

2. Données du projet

Jeu de données principal — `decrochage_etudiants_complet_V5.csv`. Chaque ligne correspond à un étudiant inscrit en L1 pour l'année universitaire 2024-2025, observé à mi-parcours du premier semestre. Le fichier contient **~5 200 lignes et 33 colonnes**. Un échantillon de 50 lignes (`decrochage_etudiants_echantillon_V5.csv`) est fourni pour une première lecture.

Données volontairement « brutes ». Comme en conditions réelles, le jeu de données contient des imperfections que vous devrez traiter : doublons, valeurs manquantes, encodages catégoriels incohérents, nombres stockés en texte (virgules décimales, symboles « % », unités « km »), dates en formats multiples, et un champ de texte libre. Trois variables sont des **leurres** sans pouvoir prédictif, destinées à tester votre rigueur méthodologique.

Cibles (apprentissage « mixte »). Deux variables-cibles sont fournies :

- **abandon** (0/1) — cible **principale** de classification : l'étudiant décroche (interrompt sa formation). C'est sur elle que porte l'analyse ROC/AUC.
- **moyenne_finale** (/20) — cible **secondaire** de régression (note finale ; structurellement basse pour les décrocheurs).

⚠ Piège de fuite de données (data leakage). `abandon = 1` correspond à un étudiant qui interrompt sa formation (décrochage) ; sa note finale est alors structurellement basse. `moyenne_finale`, résultat de fin de semestre fortement corrélé au décrochage, **ne doit jamais servir de variable explicative** pour prédire `abandon` : ce serait une fuite. Les identifiants (`student_id`, `id_dossier`) doivent également être exclus des modèles.

⚠ Piège de fuite temporelle (périmètre de scoring). La détection intervient à mi-parcours du S1. Or `moyenne_partiels_s1` et `nb_ue_validees_s1` sont des résultats consolidés en fin de S1 : les employer comme variables explicatives revient à anticiper une information indisponible au moment du scoring (performance flatteuse en validation, mais modèle inexploitable en production). Ces deux variables doivent donc rester hors du périmètre de scoring à mi-S1.

Jeu de données secondaire — catalogue_formations_V5.csv. Table de référence décrivant chaque filière (faculté, niveau, ECTS, capacité d'accueil, volume horaire, taux de réussite historique). Elle peut être jointe au jeu principal via la colonne filiere pour enrichir l'analyse (C1, C3).

2.1 Dictionnaire de données

Synthèse qualité : 5 240 lignes dont 40 doublons exacts ; taux d'abandon ~28 % ; valeurs manquantes sur 9 variables (jusqu'à 12 %) et un commentaire tuteur vide dans ~49 % des cas ; toutes les valeurs sont dans leurs bornes (aucune valeur impossible).

Variable	Type	Description	Exemple / Plage	Remarque qualité / usage
student_id	Texte	Identifiant anonyme de l'étudiant	ETU-00001	Clé — doublons à détecter / exclure du modèle
annee_universitaire	Texte	Année universitaire d'inscription	2024-2025	Constante
filiere	Texte	Filière (mention) de L1	Informatique, Droit...	Casse et espaces incohérents à normaliser
age	Entier	Âge de l'étudiant	17–27	Cohérent (population de L1)
sexe	Texte	Sexe déclaré	F / M / Autre	Encodages multiples (f, h, Femme...). Variable sensible → biais (C2)
bac_type	Texte	Type de baccalauréat	general / techno / pro	Encodages multiples. Prédicteur important
mention_bac	Texte	Mention au baccalauréat	passable / AB / B / TB	~4% manquants ; encodages multiples
etablissement_origine	Texte	Établissement d'origine	lycee_public...	~5% manquants
boursier	Binaire	Étudiant boursier	0/1 ou Oui/Non	Encodages mixtes. Variable sensible → biais (C2)
distance_domicile_km	Décimal	Distance domicile–campus (km)	0–140	~6% manquants ; unités/virgules mêlées (« 14.4 km », « 22,6 »)
heures_travail_remunere_sem	Entier	Heures de travail rémunéré / semaine	0–30	~12% manquants ; facteur socio-économique
taux_presence_pct	Décimal	Taux de présence en cours (%)	35–100	Formats « 85% », « 85,0 » (à convertir en numérique)

connexions_lms_30j	Entier	Connexions au LMS sur 30 jours	0–85	~4% manquants ; engagement
heures_lms_total	Décimal	Heures cumulées sur le LMS	0–180	Cohérent avec les connexions LMS
ressources_consultees	Entier	Ressources pédagogiques consultées	0–225	
retards_rendus	Entier	Nombre de rendus en retard	0–12	
nb_devoirs_total	Entier	Devoirs attendus dans le semestre	8–13	
nb_devoirs_rendus	Entier	Devoirs effectivement rendus	$\leq$ nb_devoirs_total	Construire un taux de rendu (feature engineering)
messages_forum	Entier	Messages postés sur le forum	0–20	
moyenne_partiels_s1	Décimal	Moyenne des partiels du S1 (/20)	0–20	Virgules décimales ; ~3% manquants. Consolidée en fin de S1 → hors périmètre de scoring à mi-S1 (fuite temporelle)
nb_ue_total	Entier	Nombre d'UE du semestre	5–7	
nb_ue_validees_s1	Entier	UE validées au S1	$\leq$ nb_ue_total	
motivation	Entier (1–5)	Auto-évaluation de la motivation	1–5	~5% manquants
satisfaction	Entier (1–5)	Satisfaction vis-à-vis de la formation	1–5	~8% manquants
sentiment_appartenance	Entier (1–5)	Sentiment d'appartenance	1–5	~7% manquants
groupe_td	Texte	Groupe de travaux dirigés	A–H	LEURRE — aucun pouvoir prédictif réel
couleur_carte_etudiante	Texte	Couleur de la carte étudiante	bleu, vert...	LEURRE
jour_inscription	Texte	Jour de la semaine d'inscription	lundi...	LEURRE (jour réel de la date, sans pouvoir prédictif)
id_dossier	Entier	Numéro de dossier administratif	6 chiffres	Identifiant — à exclure du modèle
date_inscription	Texte / Date	Date d'inscription administrative	formats mélangés	Parsing multi-format (AAAA-MM-JJ, JJ/MM/AAAA, « 02 Sep 2024 »)

commentaire_tuteur	Texte libre	Commentaire qualitatif du tuteur	~49% vide	Optionnel : analyse de texte / NLP
--------------------	-------------	----------------------------------	-----------	------------------------------------

3. Travail attendu — Notebook certifiant

Vous devez produire un notebook Jupyter unique, exécutable et lisible sans explication orale, intégrant texte, code, résultats et un journal de bord à chaque grande étape. Le notebook suit le plan imposé par le règlement de l'épreuve et doit démontrer explicitement les neuf compétences du référentiel.

Le tableau ci-dessous relie chaque compétence (C1–C9) aux attendus concrets de ce cas d'usage. *Il constitue votre fil conducteur.*

Comp.	Intitulé (abrégé)	Attendus concrets sur ce cas d'usage
C1	Identifier un jeu de données pertinent	Reformuler le besoin métier et le cas d'usage ; justifier les variables pertinentes vs leurres ; vérifier disponibilité/accès ; intégrer le catalogue des formations ; envisager des alternatives en cas de données manquantes.
C2	Risques éthiques, sociétaux & conformité	Analyser les variables sensibles (sexe, boursier, origine) ; RGPD et données scolaires ; biais possibles (sur-/sous-représentation) ; dilemme du « marquage » d'étudiants à risque ; garde-fous et information des parties prenantes.
C3	Préparer les données	Dédoublonnage ; parsing des nombres en texte (% , virgules, « km ») et des dates multi-formats ; traitement des aberrants et manquants ; normalisation des catégories ; feature engineering (taux de rendu, ratios) ; choix de stockage & cycle de vie documenté.
C4	Choisir un modèle (démarche scientifique)	Poser une baseline ; comparer plusieurs familles (régression logistique, arbres/boosting) ; justifier via la courbe ROC et l'AUC ; type de résultat (probabiliste) ; contraintes opérationnelles et éco-conception.
C5	Entraîner le modèle	Stratégie train/validation/test sans fuite ; optimisation des hyperparamètres ; feature engineering ; gestion du léger déséquilibre de classes ; description des hyperparamètres retenus.
C6	Implémenter la solution	Sérialiser le modèle + pré-traitement ; esquisser un service de prédiction (ex. API) ; versionner données/modèle ; documenter les besoins d'intégration (SI scolarité / LMS). Recommandé (non exigé) : pipeline sérialisé (joblib) + fonction predict() renvoyant une probabilité, avec contrat d'entrée/sortie explicite.
C7	Architecture cible & contraintes	Proposer une architecture (ingestion → features → inférence → restitution) ; contraintes techniques, réglementaires, organisationnelles, économiques ; acteurs à mobiliser. Recommandé (non exigé) : un schéma d'architecture et un tableau des contraintes (technique / RGPD / éco-conception / coût).
C8	Mesurer performance & impacts	Définir des indicateurs techniques (AUC, rappel, précision, F1, seuil retenu) ET métier (nb d'étudiants détectés/accompagnés, coût d'un faux négatif) ; interpréter et restituer.
C9	Amélioration continue	Cadre de suivi MLOps ; détection de dérive (drift) ; déclencheurs de ré-entraînement ; périodicité de revue des indicateurs ; versioning. Recommandé (non exigé) : un plan de monitoring (indicateurs suivis + seuils

	d'alerte de dérive) et des critères de ré-entraînement chiffrés.
--	--

3.1 Plan imposé du notebook

Reprenez la structure officielle de l'épreuve, en y intégrant le journal de bord aux étapes indiquées :

1. 0. Page de garde (titre, certification, nom/prénom, date, version, environnement d'exécution)
2. 1. Résumé exécutif (problème, objectif, approche, résultats clés, limites)
3. 2. Cadrage métier et cas d'usage — journal de bord [C1]
4. 3. Données : disponibilité, gouvernance et alternatives — journal de bord [C1]
5. 4. Enjeux éthiques, sociétaux et conformité — journal de bord [C2]
6. 5. Chargement et compréhension des données [C3]
7. 6. Analyse exploratoire (EDA) : visualisations et interprétation — journal de bord [C3]
8. 7. Préparation des données (nettoyage, manquants, transformations, features) — journal de bord [C3]
9. 8. Choix du modèle et démarche scientifique (baseline, modèles, comparaison) — journal de bord [C4]
10. 9. Entraînement, validation et ajustement (sélection du modèle final) — journal de bord [C5]
11. 10. Implémentation et mise en exploitation (déploiement, exemple d'usage) — journal de bord [C6]
12. 11. Architecture cible et contraintes [C7]
13. 12. Mesure de performance et impacts (métriques techniques + métier) [C8]
14. 13. Amélioration continue (ré-entraînement, suivi, versioning) [C9]
15. 14. Conclusion (synthèse et recommandations)
16. 15. Annexes (versions, paramètres, dépendances, fonctions utilitaires)

3.2 Exigences techniques minimales

- Détecter et supprimer les doublons ; documenter le taux de valeurs manquantes et la stratégie d'imputation retenue.
- Convertir proprement les variables numériques stockées en texte (% , virgules, « km ») et parser les dates multi-formats ; traiter les valeurs manquantes et les éventuelles incohérences résiduelles.
- Établir une baseline, puis comparer au moins deux familles de modèles ; prévenir toute fuite de données (exclure moyenne_finale et les identifiants).
- Présenter la **courbe ROC et l'AUC** (exigée par C4), la matrice de confusion, et justifier le **choix du seuil** au regard du coût métier d'un faux négatif.
- Fournir une lecture explicable des facteurs de risque (ex. importance des variables / SHAP) et discuter les leurres.
- Traiter la cible secondaire moyenne_finale en régression et rapporter une métrique adaptée (RMSE/MAE, R^2).

4. Organisation de l'évaluation

Pondération. Le cas d'usage évalue l'ensemble des compétences. Les productions écrites (jeu de données préparé + journal de bord) comptent pour 50 % et la soutenance orale pour 50 %. Les compétences C1, C2 et C4 sont en outre évaluées à 50 % par un questionnaire à visée professionnelle.

Validation. Une compétence est validée à partir de 70 % de maîtrise. La certification est obtenue si au moins 70 % des compétences sont validées et qu'aucune compétence n'est sous le seuil de 50 %.

Production écrite (3 semaines)	Soutenance orale (1 semaine après)
Notebook .ipynb exécutable (texte + code + résultats + journal de bord)	30 min de présentation de la démarche et des résultats
Jeu(x) de données utilisé(s)	30 min de questions du jury (2 professionnels externes)
Support de présentation (PPT ou PDF)	À distance ou en présentiel ; séance enregistrée

Remise de votre livrable : un unique fichier .zip nommé [Nom_prenom_certification IA], une semaine avant la soutenance à nous envoyer par mail.

5. Livrables obligatoires

- Notebook Jupyter unique (.ipynb), exécutable et structuré selon le plan imposé.
- Jeu(x) de données utilisé(s) (intégré(s) ou clairement référencé(s)).
- Support de soutenance (PDF ou PPT).
- Scripts ou fonctions utilitaires nécessaires à la reproductibilité.

6. Points clés à retenir

- Le raisonnement compte autant que le résultat : chaque décision doit pouvoir être expliquée et défendue à l'oral.
- Le jeu de données fourni est volontairement imparfait et « léger » : vous êtes invité(e) à le nettoyer, l'enrichir et le faire évoluer.
- Le journal de bord est obligatoire à chaque grande étape.
- Tous les candidats reçoivent le même sujet : démarquez-vous par la rigueur, l'explicabilité et la pertinence métier.
- Vous pouvez vous appuyer sur l'IA pour la rédaction, sans en abuser, et à condition de tout savoir justifier.