

0. Page de garde

Titre : **IA de détection précoce du décrochage étudiant**

Certification : **Concevoir et implémenter une solution d'intelligence artificielle**

Nom/prénom : **Valeux/marc**

Date : **24/08/2026**

Version : **1.0**

Environnement d'exécution : **python 3.13**

Code source : <https://github.com/marc-proxiel/ProjetDecrochage>

Résumé — extrait de `EtudeDecrochageMVA.ipynb` : résumé exécutif, mesure de performance et impacts, conclusion et recommandations, model card. Pour l'analyse complète (données, EDA, choix de modèle, architecture cible...), voir le notebook complet ou `EtudeDecrochageMVA.pdf`.

1. Résumé exécutif (problème, objectif, approche, résultats clés, limites)

1.1 Résumé Exécutif : Détection précoce du décrochage étudiant

- **Problème** L'université fait face à un **taux d'abandon élevé en première année de licence (L1)**, estimé à environ **28 %** dans le jeu de données actuel. Certaines filières, comme la Biologie ou l'Informatique, affichent des taux de réussite historiques ne dépassant pas 60 %. L'enjeu est d'intervenir avant que le décrochage ne soit définitif, car les difficultés non détectées représentent un coût important pour l'institution et l'étudiant.
- **Objectif** L'objectif principal est de concevoir une solution d'IA capable de **prédire le risque de décrochage** (classification binaire) dès le milieu du premier semestre. En complément, le modèle doit **estimer la moyenne finale** (régression) pour permettre à la Direction de la réussite étudiante de prioriser et de calibrer les dispositifs d'accompagnement, tels que le tutorat ou l'aide sociale.
- **Approche** Le projet suit une démarche de bout en bout (compétences C1 à C9) intégrée dans un **notebook Jupyter unique**. L'approche repose sur :

- Le **traitement de données brutes** complexes (doublons, valeurs manquantes, formats hétérogènes) et l'exclusion de **variables "leurres"** sans pouvoir prédictif.
- Une rigueur méthodologique stricte pour éviter les **fuites de données** (*data leakage*), en excluant notamment la moyenne finale et les résultats consolidés de fin de semestre lors de la phase de prédiction à mi-parcours.
- La comparaison de plusieurs familles de modèles (ex: régression logistique, arbres, boosting) pour sélectionner la meilleure performance.
- **Résultats clés attendus**
 - **Performance technique** : Un modèle validé par sa **courbe ROC et son AUC**, ainsi qu'une analyse de la matrice de confusion.
 - **Indicateurs métiers** : Une justification du seuil de classification basée sur le **coût d'un faux négatif** (étudiant à risque non détecté).
 - **Explicabilité** : Fournir aux équipes pédagogiques une lecture claire des facteurs de risque (ex: importance des variables).
 - **Industrialisation** : Une architecture cible incluant un plan de monitoring (MLOps) pour détecter la dérive des données dans le temps.
- **Limites et Risques**
 - **Éthique et Biais** : L'utilisation de **variables sensibles** (sexe, statut de boursier) présente un risque de biais discriminatoires qu'il convient d'analyser.
 - **Dilemme du marquage** : Le risque de stigmatisation des étudiants identifiés comme "à risque" doit être géré par des garde-fous éthiques.
 - **Qualité des données** : La présence de près de 12 % de données manquantes sur certaines variables clés et le caractère partiel des données à mi-S1 peuvent limiter la précision du modèle.

1.2 Contexte

Une université pluridisciplinaire constate un taux d'abandon élevé en première année de licence (L1). La direction de la réussite étudiante souhaite déployer une solution d'intelligence artificielle de détection précoce du décrochage afin d'identifier, **dès le milieu du premier semestre**, les étudiants à risque et de déclencher des dispositifs d'accompagnement (tutorat, soutien méthodologique, aide sociale). Les objectifs métier de la solution sont les suivants :

- prédire, à mi-parcours, le risque de décrochage (interruption de la formation) d'un étudiant à partir de ses données académiques, d'engagement et de contexte ;
- estimer la moyenne finale attendue afin de prioriser et calibrer l'accompagnement ;
- fournir aux équipes pédagogiques des indicateurs explicables, tout en garantissant un usage éthique et conforme des données étudiantes.

12. Mesure de performance et impacts (métriques techniques + métier)

Synthèse des indicateurs **techniques** (comment le modèle se comporte statistiquement) et **métier** (ce que ça signifie concrètement pour la Direction de la réussite étudiante), sur le modèle réellement retenu (régression logistique, seuil 0.5) et sur le vrai jeu de test (1040 étudiants, jamais vus à l'entraînement).

Hypothèse métier fournie : **coût d'un faux négatif ≈ 2500€** (étudiant en situation d'abandon non détecté -> pas d'accompagnement déclenché -> échec probable, coût pédagogique + administratif pour l'université).

=== Indicateurs techniques (seuil retenu) ===

```
{'seuil': 0.5, 'precision': 0.7288, 'recall': 0.8986, 'f1': 0.8048, 'roc_auc': 0.9457}
```

=== Indicateurs métier (échantillon test, 1040 étudiants) ===

Étudiants réellement en situation d'abandon : 296 (28.5%)

Détectés par le modèle (VP) : 266 -> accompagnement potentiellement déclenché

Non détectés (FN) : 30 -> coût estimé 75,000 EUR

Signalés à tort (FP) : 99 -> ressources de tutorat mobilisées inutilement

=== Extrapolation à la promotion complète (x5) ===

FN estimés : 150 -> coût estimé 375,000 EUR/an

FP estimés : 495 étudiants signalés à tort/an

Interprétation et restitution (à destination de la Direction de la réussite étudiante).

Côté technique : le modèle retenu obtient un AUC de 0.946 (très bonne capacité de classement), un rappel de 0.899 (les 9/10 des situations d'abandon sont détectées) pour une précision de 0.729 (7 signalements sur 10 sont fondés). Le seuil de décision est resté à 0.5 par défaut car il coïncide presque exactement avec l'optimum F1 (chapitre "Courbe seuil-vs-métriques").

Côté métier, sur l'échantillon de test (1040 étudiants, dont 296 réellement en situation d'abandon) :

- **266 étudiants à risque sont correctement détectés** : c'est le nombre d'étudiants pour qui un dispositif d'accompagnement (tutorat, aide sociale) peut être déclenché **à temps**, à mi-semestre.
- **30 étudiants en situation d'abandon ne sont pas détectés** (faux négatifs) : coût estimé **75 000 €** sur cet échantillon, avec l'hypothèse de 2500 €/étudiant non détecté.
- **99 étudiants sont signalés à tort** (faux positifs) : pas de coût monétaire fourni, mais un coût réel en ressources de tutorat mobilisées pour des étudiants qui n'en avaient pas besoin — la contrainte de capacité d'accueil déjà signalée (chapitre 11.2.3).

Extrapolé à l'échelle de la promotion complète (~5200 étudiants, x5 par rapport à l'échantillon test) : environ **150 étudiants non détectés par an**, soit un coût estimé de l'ordre de **375 000 €/an** avec l'hypothèse fournie. C'est ce chiffre, plus que l'AUC ou le F1, qui parle à une direction non technique.

Le levier immédiat : abaisser le seuil de décision à ~0.36 (déjà identifié au chapitre "Courbe seuil-vs-métriques") ferait tomber le rappel à 0.956, réduisant les faux négatifs à ~13 sur le test (soit ~65/an extrapolés, coût ~162 500 €/an — une **économie potentielle de plus de 200 000 €/an** sur le seul coût des faux négatifs). Le prix à payer : ~63 faux positifs supplémentaires sur le test (~315/an extrapolés), donc davantage de tutorat mobilisé pour des étudiants qui n'en avaient pas besoin. **Ce**


choix de seuil reste un arbitrage métier a valider avec la Direction (chapitre 11.2), pas une décision technique — ce chapitre fournit les chiffres pour le trancher, pas la décision elle-même.


12.1 Explicabilité individuelle : pourquoi CET étudiant précis est signalé

Le diagramme SHAP du chapitre 9.2.1 (beeswarm) explique le modèle **globalement** (quelles variables comptent en général). Utile pour valider le modèle, mais un conseiller pédagogique face a un étudiant précis a besoin d'une explication **individuelle** : pourquoi *celui-ci*, pas les autres. C'est ce qu'apporte un **waterfall plot** (diagramme en cascade), sur les deux cas extrêmes du jeu de test.

Etudiant a risque (ligne 447) : proba_abandon = 0.998

Etudiant peu a risque (ligne 107) : proba_abandon = 0.00002





12.1.1 Comment lire ce graphique (explication côté métier)

Chaque barre est une variable de cet étudiant précis. Pour un conseiller pédagogique qui n'a jamais vu de SHAP :

- **On part d'une valeur de reference $E[f(x)]$** (en bas du graphique) : c'est le "risque moyen" si on ne savait rien de l'étudiant — la base de comparaison.
- **Chaque barre rouge pousse le risque vers le haut** (cette caractéristique de l'étudiant AUGMENTE son risque d'abandon par rapport a la moyenne).
- **Chaque barre bleue pousse le risque vers le bas** (cette caractéristique le DIMINUE).
- **La taille de la barre = l'importance de cette caractéristique POUR CET ÉTUDIANT PRÉCIS** (pas en général — un même facteur peut compter beaucoup pour un étudiant et peu pour un autre).
- **On arrive a $f(x)$** en haut : le score final de cet étudiant, qui correspond a `proba_abandon` affiche au-dessus du graphique.

Message a retenir pour le métier : ce graphique permet de dire a un conseiller "cet étudiant est signalé a cause de X et Y, malgré un effet positif de Z", plutôt que de présenter une probabilité brute sans justification — c'est cette justification qui crée la confiance nécessaire a l'adoption de l'outil (chapitre 11.2.7), et qui permet au conseiller de cibler l'accompagnement sur les vrais leviers plutôt que d'agir a l'aveugle.

14. Conclusion et recommandations

14.1 Conclusion

Deux modèles indépendants, valides de bout en bout (comparaison, validation croisée, tuning, SHAP, calibration) :

- **Classification** `abandon` : régression logistique ($C=0.01$), retenue devant Random Forest et Gradient Boosting car la relation avec les variables d'engagement est globalement linéaire (chapitre 6). AUC **0.946**, rappel **0.899**, précision 0.729 sur le test (1040 étudiants jamais vus a l'entraînement).
- **Régression** `moyenne_finale` : Gradient Boosting Regressor, retenu a l'inverse car la note continue dépend d'interactions plus complexes. R2 **0.692**, MAE **2.25 points/20**.
- Les deux modèles restent **strictement indépendants** (pas de stacking, pas de fuite croisée) tout en étant appelables ensemble (`predire_etudiant` , `/predict-tabular`).

Impact métier chiffre (chapitre 12, hypothèse 2500€/faux négatif) : sur l'échantillon test, 266 étudiants a risque sur 296 sont correctement détectés ; les 30 non détectés représentent un coût estime de 75 000€, soit environ **375 000€/an** extrapole a la promotion complète (~5200 étudiants). Abaisser le seuil a ~0.36 reduirait ce coût a ~162 500€/an, au prix de faux positifs supplémentaires — **un arbitrage a trancher avec la Direction, pas un choix technique**.

Infrastructure complète et testée réellement (pas seulement codee) : API FastAPI conteneurisee servant les deux modèles, CLI, orchestration Prefect (entraînement + scoring batch + stockage PostgreSQL), suivi MLflow (2 experiences, 2 modèles enregistres), monitoring Prometheus/Grafana avec 7 alertes (exploitation et dérive), 45+ tests automatisés. L'ensemble a été demarre, appele et vérifié en conditions réelles a plusieurs reprises dans ce notebook.

Ce qui manque pour un vrai service (chapitre 11) n'est pas principalement technique : c'est la couche de **gouvernance humaine** — qui valide un nouveau modèle, qui arbitre le seuil, qui audite les accès, qui forme les conseillers pédagogiques.

14.2 Recommandations

Par ordre de priorité :

1. **Faire trancher le seuil de décision par la Direction de la réussite étudiante**, avec les chiffres du chapitre 12 (coût des faux négatifs vs capacité d'accueil du tutorat, chapitre 11.2.3). C'est le point le plus bloquant et le plus rapide a débloquent : une décision, pas du développement.
2. **Mettre en place un gate humain avant toute promotion de modèle** en production (aujourd'hui, `decrochage_train` remplacé directement l'artefact) — éviter qu'une régression de performance ou un biais passe inaperçu.
3. **Connecter le pipeline au vrai SI scolarité/LMS** de l'université plutôt qu'a des CSV manuels — condition prealable a toute mise en production réelle.

4. **Construire la couche de consommation métier** (dashboard + notification tuteur, chapitre 11) : sans elle, le service reste un outil technique, pas un service utilisable par la Direction.
5. **Traiter les obligations RGPD concrètement** : purge programmée de la table `predictions`, journal d'audit, base légale validée avec le DPO (chapitre 11.2.1) — déjà cadre éthiquement (chapitre 4), pas encore implémenté.
6. **Réévaluer le biais des variables sensibles à chaque nouvelle version** du modèle (`sexe`, `boursier` déjà retirées des features, mais l'impact réel sur différents sous-groupes n'a jamais été mesuré empiriquement).
7. **Versionner les données avec DVC** (déjà dans les dépendances, jamais utilisé dans cette session) en plus des modèles — savoir sur quelles données exactes une version a été entraînée.
8. **Former les conseillers pédagogiques** à l'explicabilité déjà disponible (coefficients, SHAP global et individuel, chapitre 9.2.1) — un modèle juste mais incompris ne sera pas adopté.

Aucune de ces recommandations ne remet en cause les modèles retenus : elles portent toutes sur ce qu'il faut construire **autour** d'eux pour passer d'un pilote validé à un service exploité.

14.3 Coûts et retour sur investissement (ROI) : seuil 0.5 vs seuil 0.33

Le seuil de décision (chapitre 8.1.3, "Courbe seuil-vs-métriques") a été laissé à 0.5 par défaut dans ce notebook, mais un seuil plus bas (~0.33-0.36) a été identifié comme un levier pour réduire les faux négatifs (chapitre 12). Chiffrage côte à côte des deux seuils, sur le même jeu de test et le même modèle réellement entraîné (pas de simulation).

Hypothèses de coût :

- Coût d'un faux négatif : **2500 €** (déjà utilisé chapitre 12, hypothèse métier fournie).
- Coût d'un accompagnement déclenché (tutorat/encadrement, par étudiant signalé, TP + FP) : **200-500 €/an**, repris de l'estimation "Encadrement" de l'annexe (chapitre 15.1.3) — aucune mesure propre à ce projet n'existe, c'est une **approximation à affiner avec la Direction**, pas une donnée mesurée.
- Extrapolation à la promotion complète (~5200 étudiants, facteur x5) : même méthode que chapitre 12.

Lecture du tableau.

Seuil	Rappel	TP/an	FP/an	FN/an	Coût FN/an	Coût accompagnement/an	Économie vs aucune détection	ROI
0.50	0.899	~1330	~495	~150	375 000 €	~639 000 €	~2 686 000 €/an	4.2
0.33	0.966	~1430	~840	~50	125 000 €	~795 000 €	~2 781 000 €/an	3.5

- **Les deux seuils sont largement positifs** : même dans le pire cas (coût d'accompagnement à 500 €/étudiant), l'économie nette reste de plusieurs millions d'euros par an par rapport à l'absence totale de détection (3.7 M€/an de coût si aucun abandon n'est détecté).

- **Passer de 0.5 à 0.33 crée de la valeur nette supplémentaire** : ~100 faux négatifs évités/an de plus (soit ~250 000 € évités), au prix de ~345 accompagnements supplémentaires/an (soit ~156 000 € de plus au coût moyen) — un **gain net marginal d'environ +95 000 €/an**.
- **Mais le ROI (ratio) baisse légèrement** (4.2 -> 3.5) : le seuil 0.33 est moins "efficient" par euro dépense en accompagnement, car il ajoute proportionnellement plus de faux positifs (168 vs 99 sur le test) que de vrais positifs supplémentaires. C'est le même arbitrage rappel/précision que la courbe seuil-vs-métriques (chapitre 8.1.3), traduit ici en euros plutôt qu'en score.
- **Limite importante de ce chiffrage** : le coût d'accompagnement (200-500 €/étudiant) est une approximation reprise de l'annexe (chapitre 15.1.3, poste "encadrement" d'un redoublant), pas une mesure du coût réel d'un dispositif de tutorat déclenché à mi-semester. De même, ce calcul suppose implicitement qu'un accompagnement déclenché sur un vrai positif **évite effectivement** le décrochage — hypothèse optimiste, jamais mesurée dans ce projet (aucune donnée de suivi post-intervention disponible).

Conclusion : sur la seule dimension financière, le seuil 0.33 est préférable (gain net supérieur), mais le choix reste, comme déjà signalé (chapitre 11.2.3 et 11.2), un **arbitrage à valider avec la Direction** — notamment sur la capacité réelle du dispositif de tutorat à absorber ~345 accompagnements supplémentaires par an.

15.2 Model Card

Fiche de synthèse des deux modèles retenus (format inspiré de Mitchell et al., "Model Cards for Model Reporting", 2019), pour un lecteur qui n'a pas le temps de parcourir tout le notebook. Chaque affirmation renvoie au chapitre qui la détaille et la justifie.

Détails des modèles

	Classifieur <code>abandon</code>	Régresseur <code>moyenne_finale</code>
Type	Régression logistique (<code>LogisticRegression</code>)	Gradient Boosting (<code>GradientBoostingRegressor</code>)
Hyperparamètres retenus	<code>C=0.01</code> , <code>class_weight="balanced"</code> , <code>max_iter=1000</code>	<code>n_estimators=100</code> , <code>max_depth=3</code> , <code>learning_rate=0.1</code>
Choix motivé	comparaison + validation croisée + tuning + SHAP (chapitres 8, 9.1-9.4)	comparaison + tuning (chapitre 9.5)
Version / seed	<code>model_metadata.json</code> , version 0.1.0, <code>random_seed=42</code>	idem
Enregistrement	MLflow Model Registry <code>decrochage- abandon-logistique</code>	MLflow Model Registry <code>decrochage- moyenne-finale-gb</code>
Développeur / dépôt	Marc Valeux — github.com/marc-proxiel/ProjetDecrochage	idem

Usage prévu

- **Cas d'usage** : signaler, à mi-semestre (S1), les étudiants de L1 à risque de décrochage (`abandon`) et estimer leur note finale probable (`moyenne_finale`), pour aider la Direction de la réussite étudiante à prioriser les dispositifs d'accompagnement (tutorat, soutien méthodologique, aide sociale) — chapitre 2.
- **Utilisateurs prévus** : Direction de la réussite étudiante, conseillers pédagogiques (via un futur dashboard métier, chapitre 11.1.5) — jamais l'étudiant directement, jamais de décision automatique (chapitre 11.2.2, RGPD art. 22).
- **Hors périmètre** : décision automatisée sans humain (sanction, refus d'inscription) ; usage sur une autre population que des L1 de cette université sans ré-entraînement (chapitre 3) ; usage au-delà du mi-semestre S1, les features correspondant spécifiquement à cette période (chapitre 5) ; évaluation d'un enseignant ou d'une filière.

Facteurs pertinents

- **Variables sensibles** (chapitre 4) : `sexe` , `boursier` — **exclues des features** d'entraînement (chapitre 5.1.5) pour limiter le biais direct, mais un biais indirect via des variables corrélées (`heures_travail_remunere_sem` , `distance_domicile_km`) reste possible et **n'a jamais été mesuré empiriquement** (chapitre 14.2, recommandation 6).
- **Autres facteurs utilisés** : `filieres` , `bac_type` , `mention_bac` , `etablissement_origine` — risque de biais systémique si une filière ou un type de bac est structurellement lié à des facteurs socio-économiques (chapitre 2.6).

Données

- **Source** : `dataset_decrochage_etudiants_complet_V5.csv` (5240 lignes, 33 colonnes, année 2024-2025) enrichi de `dataset_catalogue_formations_V5.csv` (8 filières) — chapitre 3.1.
- **Nettoyage** : 40 doublons exacts supprimés (5200 lignes utiles), jusqu'à 12 % de valeurs manquantes sur certaines colonnes, imputées par médiane **fit sur le train uniquement** (chapitres 7.11, 7.13 — anti-fuite train/test).
- **Split** : 80/20 stratifié sur `abandon` , `random_state=42` — 4160 lignes train, **1040 lignes test jamais vues à l'entraînement** (chapitre 7.13).
- **Déséquilibre de la cible** : 28.4 % d'abandon (chapitre 6.1), compensé par `class_weight="balanced"` pour le classifieur, pas de SMOTE.

Métriques (sur le test, 1040 étudiants)

Classifieur	<code>abandon</code> (seuil 0.5)	Régresseur	<code>moyenne_finale</code>
ROC AUC	0.946	R ²	0.692
Précision	0.729	MAE	2.25 points/20
Rappel	0.899	RMSE	3.05 points/20
F1	0.805		

Détail complet (comparaison de modèles, validation croisée, calibration, SHAP) : chapitres 8, 9.1-9.4.
 Seuil de décision : **0.5 par défaut** (coïncide avec l'optimum F1) ; alternative **0.33** chiffrée en euros au

chapitre 14.3 (économie nette supérieure mais ROI ratio inférieur — arbitrage non tranché avec la Direction).

Considérations éthiques

- RGPD : identifiants (`student_id` , `id_dossier`) exclus ; base légale du traitement non encore validée avec le DPO (chapitre 11.2.1).
- Dilemme du marquage / stigmatisation : un score n'est jamais montré tel quel, doit rester une aide à la décision humaine, jamais une décision automatique (chapitres 2.9, 11.2.2).
- Explicabilité : SHAP global (chapitre 9.2.1) et individuel (chapitre 12.1) disponibles pour justifier chaque signalement auprès d'un conseiller.

Limites et recommandations

- Aucune mesure de l'efficacité réelle d'un accompagnement déclenché sur la base d'un signalement — hypothèse optimiste implicite dans le chiffrage ROI (chapitre 14.3).
- Biais résiduel sur les variables sensibles non mesuré empiriquement (recommandation 6, chapitre 14.2).
- Modèle non testé sur une autre cohorte/année : la dérive doit être surveillée (Prometheus/Grafana, chapitre 10.6) et le modèle ré-entraîné selon le calendrier académique (chapitre 13.1).
- Pas de gate humain avant promotion d'une nouvelle version en production (recommandation 2, chapitre 14.2).